

Kaggle S6E7 — EDA Bulguları ve Preprocessing Karar Raporu

EDA çalışma günlüğü

2026-07-04

İçindekiler

Yönetici özeti	1
1. Veri sözleşmesi ve kapsam	2
2. Target dağılımı	2
3. Ham feature–target ilişkileri	3
3.1 Numeric feature'lar	3
3.2 Kategorik feature'lar	3
4. Missing value analizi	4
4.1 Missing oranları	4
4.2 Missingness target sinyali	4
5. Train-test dağılım kayması	4
5.1 Numeric shift	4
5.2 Kategorik shift	6
6. Outlier analizi	6
6.1 Outlier oranları	6
6.2 Outlier ve target	6
7. Feature engineering adayları	8
7.1 Ratio feature'lar	8
7.2 Kategorik interaction'lar	8
7.3 Rule-based flag'ler	9
8. Preprocessing kararı ve deney önerisi	9
Preprocess V1 — güvenli baseline	9
Preprocess V2 — önerilen ilk feature set	9
Preprocess V3 — kontrollü clipping deneyi	9
Önerilen ilk deney sırası	9
9. Riskler ve sınırlamalar	10
10. Artefakt kataloğu	10
Grafikler	10
Tablolar	10
11. Son karar günlüğü	10

Yönetici özeti

Bu rapor, beş EDA notebookunun temiz kernel ile yeniden çalıştırılmasıyla üretilen tüm tablo ve grafik artefaktlarını birlikte yorumlar. Amaç model seçmek değil; modelleme öncesi missing value, dağılım kayması, outlier ve feature engineering kararlarını kanıta bağlamaktır.

Öne çıkan sonuçlar:

1. **Target ciddi biçimde dengesizdir.** at-risk %85,87, unhealthy %8,36 ve fit %5,77 oranındadır. Gelecekte ana metrik balanced accuracy, zorunlu yardımcı metrik sınıf bazlı recall olmalıdır.
2. **Train ve test genel olarak aynı üretim sürecinden görünmektedir.** Numeric KS istatistiklerinin tamamı 0,0034'ün altındadır; missing oranları neredeyse birebir aynıdır. Belirgin tek shift gender dağılımındadır (TVD 0,0331).
3. **Missingness çoğu kolonda zayıf, BMI'da ise güçlü target sinyali taşır.** BMI missing satırlarda unhealthy oranı %2,93'e düşerken fit %8,20'ye çıkar. Missing flag'leri korunmalı; yalnız missing_count tek başına güçlü görünmemektedir.
4. **Uç değerler hata gibi değil, sınıf sınırlarının parçası gibi davranmaktadır.** Düşük uyku, yüksek BMI, düşük BMI, yüksek adım ve yüksek egzersiz uçları target dağılımını ciddi biçimde değiştirir. Satır silmek bilgi kaybına yol açabilir.
5. **En güçlü ham sinyaller** uyku süresi, BMI, adım sayısı, egzersiz süresi, stress seviyesi ve fiziksel aktivitedir. Heart rate ve water intake tek başına daha zayıftır.
6. **Preprocess V2 ilk modelleme adayıdır:** median/missing imputasyon + missing flag/count + ratio + kategorik interaction + train kaynaklı outlier flag. Clipping ve rule-based flag'ler ayrı ablation deneyleri olmalıdır.


1. Veri sözleşmesi ve kapsam

Öğrenme seti	Satır	Kolon
Train	690.088	15
Test	295.753	14

- Kimlik kolonu: id
- Target: health_condition
- Numeric feature sayısı: 7
- Kategorik feature sayısı: 6
- Train feature kolonları test ile uyumludur; testte target yoktur.
- Bütün feature kolonlarında missing değer vardır; id ve target eksiksizdir.
- Bu aşamada model, cross-validation veya leaderboard sonucu üretilmemiştir.

2. Target dağılımı

Sınıf	Adet	Oran
at-risk	592.561	%85,87
unhealthy	57.724	%8,36
fit	39.803	%5,77



Yorum: Sadece çoğunluk sınıfını tahmin eden anlamsız bir yaklaşım yaklaşık %85,9 accuracy elde edebilir. Bu nedenle accuracy optimizasyonu yanlış yönlendirir. fit recall ve unhealthy recall özellikle izlenmeli; fold'lar target bakımından stratified kurulmalıdır.

3. Ham feature–target ilişkileri

3.1 Numeric feature'lar

Feature	at-risk medyan	fit medyan	unhealthy medyan	Yorum
sleep_duration	7,03	7,84	5,53	En net ayrımlardan biri; düşük uyku unhealthy ile
heart_rate	75,10	74,50	75,10	Merkezi değerlerde sınıf ayrımı zayıf.
bmi	22,96	22,25	23,70	Fit daha düşük, unhealthy daha yüksek; uçlarda i
calorie_expenditure	2.235	2.345	2.255	Fit sınıfında daha yüksek, fakat sınıflar örtüşüyor.
step_count	8.483	12.342,5	8.941,5	Fit sınıfını ayıran güçlü hareket sinyali.
exercise_duration	38,60	50,50	39,70	Fit sınıfında belirgin biçimde yüksek.
water_intake	2,18	2,14	2,18	Tek başına zayıf; oran veya uç değer olarak incel

Korelasyon: En yüksek doğrusal ilişkiler step_count–exercise_duration (0,438), step_count–calorie_expenditure (0,400) ve exercise_duration–calorie_expenditure (0,394) çiftlerindedir. Bunlar aynı aktivite eksenini kısmen tekrarlar, ancak GBDT için otomatik silme gerekçesi değildir. Ratio feature'ların ek değerinin ablation ile ölçülmesi gerekir.

3.2 Kategorik feature'lar

- stress_level=high: %27,87 unhealthy; low: %20,06 fit; medium: %99,39 at-risk. En güçlü kategorik sinyaldir.
- physical_activity_level=active: %17,16 fit. moderate ve sedentary seviyelerinde fit oranı sırasıyla yalnız %0,31 ve %0,24'tür.
- sleep_quality=poor: %13,58 unhealthy; good: %8,17 fit ve yalnız %3,05 unhealthy.
- smoking_alcohol=yes: %11,20 unhealthy; no: %7,86 fit ve %5,46 unhealthy.
- diet_type farkları sınırlıdır: fit oranı %5,16–%6,12 aralığındadır.
- gender target ile görece zayıf ilişkilidir; buna rağmen train-test shift nedeniyle encoding sağlam olmalıdır.

4. Missing value analizi

4.1 Missing oranları

Feature	Train missing	Test missing	Train-test farkı
stress_level	%12,00	%12,00	yaklaşık 0
sleep_duration	%11,01	%11,01	yaklaşık 0
sleep_quality	%8,45	%8,45	yaklaşık 0
calorie_expenditure	%7,66	%7,66	yaklaşık 0
water_intake	%6,30	%6,30	yaklaşık 0
physical_activity_level	%5,31	%5,31	yaklaşık 0
smoking_alcohol	%4,14	%4,14	yaklaşık 0
gender	%3,10	%3,10	yaklaşık 0
step_count	%2,02	%2,02	yaklaşık 0
bmi	%2,01	%2,01	yaklaşık 0
heart_rate	%1,14	%1,14	yaklaşık 0
exercise_duration	%1,00	%1,00	yaklaşık 0
diet_type	%1,00	%1,00	yaklaşık 0

Missing oranlarının train ve testte altı ondalık basamağa kadar benzer olması, shift riskinin düşük olduğunu ve missing mekanizmasının veri üretim sürecinde kontrollü olabileceğini düşündürür.

4.2 Missingness target sinyali

Feature missing olduğunda	at-risk	fit	unhealthy	Değerlendirme
bmi	%88,88	%8,20	%2,93	Çok güçlü ve sıra dışı sinyal; flag zorunlu aday.
heart_rate	%87,08	%5,53	%7,39	Orta düzey fark.
exercise_duration	%85,09	%6,04	%8,87	Küçük fakat yönlü fark.
diet_type	%86,76	%5,09	%8,16	Küçük fark.
gender	%85,83	%5,57	%8,60	Küçük fark.
water_intake	%85,51	%5,81	%8,69	Küçük fark.
stress_level	%85,89	%5,75	%8,36	Global dağılıma çok yakın.

missing_count=0 olan 349.623 satırda sınıf dağılımı globale çok yakındır. Count 1–3 için de değişim küçüktür. Count 5 yalnız 87, count 6 yalnız 9 satır içerdiğinden bu seviyelerdeki oranlar güvenilir değildir.


Karar:

- Numeric: median imputasyon.
- Kategorik: açık missing seviyesi.
- Her missing kolon için _is_missing flag.
- missing_count düşük maliyetli aday olarak tutulabilir; tek başına güçlü bir sinyal olduğu varsayılmamalıdır.
- BMI missing flag'i kesinlikle ablation kapsamına alınmalıdır.

5. Train-test dağılım kayması

5.1 Numeric shift

Feature	KS statistic	Train medyan	Test medyan	Sonuç
water_intake	0,00336	2,17	2,18	Çok küçük fark.
step_count	0,00235	8.856	8.857	İhmal edilebilir.
heart_rate	0,00200	75,10	75,10	İhmal edilebilir.
sleep_duration	0,00179	6,99	6,99	İhmal edilebilir.
calorie_expenditure	0,00168	2.241	2.240	İhmal edilebilir.
exercise_duration	0,00165	39,40	39,40	İhmal edilebilir.
bmi	0,00113	22,99	22,99	İhmal edilebilir.



Büyük örneklemede p-value aşırı hassas olabileceği için karar KS statistic ve percentile tablolarıyla verilmiştir. %0,1–%99,9 percentile değerleri de train ve test arasında çok yakındır.

5.2 Kategorik shift

Feature	Total variation distance	Test-only kategori
gender	0,03309	Yok
physical_activity_level	0,00856	Yok
smoking_alcohol	0,00204	Yok
sleep_quality	0,00133	Yok
stress_level	0,00122	Yok
diet_type	0,00083	Yok

gender farkının kaynağı: female train'de %32,46 iken testte %29,15; other train'de %29,99 iken testte %33,11'dir. Male ve missing oranları stabildir. Unknown kategori bulunmaması olumlu olsa da gelecekteki encoder unknown seviyeleri güvenle ele almalıdır.

Karar: Adversarial validation şu an zorunlu görünmüyor; modelleme aşamasında E001 baseline sonrasında opsiyonel tanı deneyi olabilir. Gender için performansın train dağılımına aşırı bağlanmadığı kontrol edilmelidir.

6. Outlier analizi


6.1 Outlier oranları

Feature	IQR oranı	%0,5–%99,5 quantile oranı	Not
sleep_duration	%0,29	%0,84	Alt ve üst uç target ile ilişkili.
heart_rate	%0,41	%0,97	Sınıf ayrımı daha zayıf.
bmi	%0,78	%0,97	Uçlarda çok güçlü sınıf sinyali.
calorie_expenditure	%1,86	%0,91	IQR görece agresif.
step_count	%0,00	%0,96	Bounded dağılım; IQR outlier bulmuyor.
exercise_duration	%0,02	%0,49	Alt eşik 0 olduğu için low flag üretmiyor.
water_intake	%1,65	%0,89	IQR görece agresif.

Train'de öğrenilen quantile eşikleri testte hemen hemen aynı outlier oranlarını üretmiştir. En büyük mutlak fark düşük heart rate flag'inde yalnız 0,10 yüzde puandır. Bu da eşiklerin train-test arasında stabil olduğunu gösterir.

6.2 Outlier ve target


- Düşük uyku outlier'larında unhealthy %42,05; normal grupta %8,22.
- Yüksek uyku outlier'larında fit %9,56; unhealthy yalnız %0,14.
- Düşük BMI outlier'larında fit %49,62; unhealthy %0.
- Yüksek BMI outlier'larında unhealthy %68,02; fit %0.
- Yüksek step count outlier'larında fit %17,92.
- Yüksek exercise duration outlier'larında fit %17,57.
- Yüksek calorie expenditure outlier'larında fit %12,02 ve unhealthy %11,54.
- Yüksek water intake outlier'larında unhealthy %12,17.



Karar: Outlier silme yapılmamalıdır. Uç değerler büyük ölçüde target mekanizmasının parçasıdır. Train quantile outlier flag'leri V2'ye adaydır. Clipping ancak V3 olarak, aynı cross-validation fold'larında V2'ye karşı test edilmelidir.

7. Feature engineering adayları

7.1 Ratio feature'lar



- exercise_per_bmi: fit ortalaması 2,223; at-risk 1,602; unhealthy 1,570. En temiz ratio adaylarından biridir.
- calorie_per_step: fit medyanı 0,198; at-risk 0,259; unhealthy 0,254. Fit için daha düşük ve daha dar dağılım vardır.
- calorie_per_exercise_min: fit medyanı 46,24; at-risk 55,86; unhealthy 55,27. Exercise duration sıfıra yakın olduğunda üst kuyruk 2.000'in üzerine çıkar.
- step_per_exercise_min: fit dağılımı daha dar; at-risk/unhealthy üst kuyrukları çok uzundur.
- water_per_bmi: fit ortalaması 0,0968; unhealthy 0,0880. Fark vardır fakat diğer ratio'lara göre daha sınırlıdır.
- steps_per_sleep_hour: unhealthy medyanı 1.392,9; fit 1.364,1; at-risk 1.052,2. Unhealthy üst kuyruğu belirgindir.

Risk: Exercise denominator'lı ratio'larda sıfıra yakın değerler yapay uzun kuyruk oluşturur. Mevcut +1 koruması sonsuz değeri önler; yine de ratio outlier flag veya log1p ablation'ı düşünülmelidir. Kör clipping yapılmamalıdır.

7.2 Kategorik interaction'lar

- high__poor stress/sleep birleşiminde unhealthy %43,24.

- high__average ve high__missing birleşimlerinde unhealthy yaklaşık %27,7.
- low__good birleşiminde fit %27,72; unhealthy %0,27.
- medium__* birleşimlerinin tamamında at-risk yaklaşık %99,4'tür.
- active__balanced ve active__veg activity/diet birleşimlerinde fit yaklaşık %18'dir.
- no__active smoking/activity birleşiminde fit %22,54.
- yes__active birleşiminde unhealthy %11,93 ve fit %11,40'tır.
- Gender/activity interaction'larında ayrımın büyük bölümü activity'den gelir; gender ek katkısı sınırlı görünür.

Karar: stress_sleep_quality, activity_diet ve smoking_activity V2 adaylarıdır. gender_activity, hem daha zayıf ek sinyal hem de gender shift nedeniyle ayrı ablation ile değerlendirilmelidir.

7.3 Rule-based flag'ler

Flag aktifken	fit	unhealthy	Yorum
low_sleep <6	%0,23	%36,80	Çok güçlü unhealthy sinyali.
high_sleep >9	%11,16	%0,32	Fit yönlü sinyal.
high_bmi >=30	%0,00	%83,10	Çok güçlü unhealthy sinyali.
low_bmi <18,5	%20,34	%0,00	Fit yönlü sinyal.
high_heart_rate >100	%6,54	%1,96	Çok az gözlem olabilir; dikkatli yorumlanmalı.
low_heart_rate <60	%5,17	%6,78	Zayıf/orta sinyal.
low_steps <3000	%0,24	%8,06	Fit yokluğu belirgin.
high_steps >12000	%12,00	%8,48	Fit oranını artırıyor.

Bu flag'ler target ile güçlü ilişkilidir; ancak eşiklerin bir kısmı ham feature'ın öğrenebileceği ayrımı elle tekrar eder. Bu yüzden V2'ye otomatik eklenmemeli, V2 üzerine ayrı bir rule-feature ablation deneyi olmalıdır.

8. Preprocessing kararı ve deney önerisi

Preprocess V1 — güvenli baseline

- Numeric median imputasyon; değer yalnız fold-train'den öğrenilir.
- Kategorik missing seviyesi: missing.
- Her missing kolon için flag.
- Unknown category handling.
- Satır silme ve clipping yok.

Preprocess V2 — önerilen ilk feature set

V1'e ek olarak:

- missing_count
- Altı ratio feature
- stress_sleep_quality, activity_diet, smoking_activity
- Train/fold-train %0,5–%99,5 eşiklerinden outlier flag'leri
- outlier_count

gender_activity ayrı ablation'da değerlendirilmelidir.

Preprocess V3 — kontrollü clipping deneyi

- V2 + numeric ve ratio feature'larda fold-train %0,1–%99,9 clipping.
- V2'yi geçmedikçe kabul edilmemelidir.

Önerilen ilk deney sırası

Deney	Amaç
E001	Preprocess V1 ile modelden bağımsız güvenli baseline sözleşmesi
E002	V1 + missing_count; missing count'un marjinal katkısı

Deney	Amaç
E003	V1 + ratio feature'lar
E004	V1 + kategorik interaction'lar
E005	V1 + outlier flag/count
E006	Tam V2
E007	V2 + gender_activity
E008	V2 + rule-based flags
E009	V3 clipping karşılaştırması

Bu sıra model seçimini tanımlamaz; yalnız preprocessing ablation mantığını kayıt altına alır.

9. Riskler ve sınırlamalar

- Bulgular ilişkiseldir; nedensellik veya tıbbi geçerlilik iddiası taşımaz.
- Dataset sentetik/yarı sentetik bir üretim mekanizmasına sahip olabilir; keskin eşikler target üretim kuralını yansıtır olabilir.
- Target'a bakarak feature seçmek mümkündür, ancak gerçek katkı yalnız stratified cross-validation ile doğrulanmalıdır.
- Nadir alt gruplarda oranlar yanıltıcı olabilir; interaction/flag tabloları modelleme öncesinde gözlem sayısı ile birlikte filtelenmelidir.
- KS p-value büyük örneklemede tek başına karar ölçütü değildir.
- Test distribution'a bakmak preprocessing sözleşmesini sağlamlaştırmak içindir; target bilgisi olmadığı için performans garantisi vermez.

10. Artefakt kataloğu

Grafikler

Artefakt	İçerik
01_target_distribution.png	Target sınıf oranları
03_numeric_shift_ecdf.png	Numeric train-test ECDF karşılaştırmaları
04_outlier_count.png	Satır başına outlier sayısı
05_ratio_by_target.png	Ratio feature'ların target bazlı boxplotları

Tablolar

Artefakt	İçerik
01_target_distribution.csv	Target adet ve oranları
02_missing_summary.csv	Train/test missing oranları ve farkları
02_missingness_target.csv	Her missing flag için sınıf dağılımı
02_missing_count_target.csv	Satır başına missing sayısı ve target oranları
03_numeric_shift.csv	Mean, median, std ve KS sonuçları
03_numeric_percentiles.csv	Train/test %0,1–%99,9 percentile değerleri
03_categorical_shift.csv	TVD, unique ve unseen category sonuçları
04_outlier_summary.csv	IQR ve quantile outlier eşikleri/oranları
04_train_test_outlier_rates.csv	Train kaynaklı eşiklerin train/test oranları
04_outlier_target.csv	Outlier flag ve target ilişkisi
05_ratio_target_summary.csv	Ratio feature'ların sınıf bazlı dağılımı
05_interaction_target.csv	Kategorik interaction target oranları
05_rule_target.csv	Rule-based flag target oranları

11. Son karar günlüğü

- **Kabul:** Balanced accuracy + sınıf bazlı recall değerlendirme standardı.

- **Kabul:** Satır silmeme.
- **Kabul:** Numeric median, kategorik `missing`, unknown handling ve missing flag içeren V1.
- **Kabul:** BMI missing flag'ini zorunlu aday olarak değerlendirme.
- **Aday:** Ratio, seçilmiş interaction ve outlier flag içeren V2.
- **Aday:** `gender_activity` ve rule-based flag'leri ayrı ablation olarak test etme.
- **Aday:** V3 clipping; yalnız V2'ye karşı doğrulanırsa kabul.
- **Red:** IQR ile otomatik outlier silme.
- **Red:** Accuracy'yi tek performans metriği olarak kullanma.