

Kaggle S6E7 — Nihai Deney Sonuçları ve Submission Karar Raporu

Deney pipeline artefaktlarından otomatik üretilmiştir

2026-07-04

Yönetici özeti

Bu rapor, tamamlanan **7 ana model deneyi**, **4 OOF class-multiplier optimizasyonu** ve **20 LightGBM sweep trial'ını** submission seçimi için tek karar paketinde toplar. Bütün skorlar train etiketlerinden üretilen out-of-fold (OOF) tahminlere dayanır; test etiketi ve public leaderboard bilgisi optimizasyonda kullanılmamıştır.

En önemli sonuçlar:

- En iyi doğrudan argmax model E008:** balanced accuracy 0.914002 ± 0.001098 . Sqrt-balanced sample weight, E002'ye göre $+0.037065$ kazandırmıştır.
- En iyi tuned OOF sonucu E002:** 0.948584 . Class multiplier tuning dört kaynak modelin tamamını yaklaşık 0.948 seviyesine taşımıştır.
- En iyi sweep SWEEP_002:** 0.877851 ; E002'ye göre yalnız $+0.000915$ ve E001'e göre -0.000252 fark üretmiştir. Sweep, sınıf ağırlığı kadar güçlü bir kazanım sağlamamıştır.
- Submission seçimindeki ana belirsizlik multiplier overfit riskidir.** Aynı OOF üzerinde multiplier seçilip skorlandığı için tuned skorlar bağımsız doğrulama skoru değildir.
- Karar için güvenli kısa liste:** E008 argmax, E002 tuned, E006 tuned, E008 tuned ve çeşitlilik kontrolü için SWEEP_002 argmax. İlk gönderimlerde argmax/tuned çifti, postprocess'in gerçek leaderboard katkısını ölçmek için birlikte değerlendirilebilir.

1. Kapsam, veri ve tekrar üretilebilirlik

Alan	Değer
Train satırı	690,088
Test satırı	295,753
Ham feature	13 (7 numeric + 6 categorical)
Target	health_condition
Sınıflar	at-risk, fit, unhealthy
CV	StratifiedKFold, 3 fold, shuffle, seed 42
Model	LightGBM 4.6.0, CPU/OpenMP, n_jobs=6
Python	3.12.7
Train SHA-256	424d744d0344b14b7888b901d79db536f6ffbe73229809a736247ff812416f
Test SHA-256	34914866109ab01c806adc25634fef1639d7574368a13d48ebe3037367365e

Gerçek train sınıf dağılımı:

Sınıf	Adet	Oran
at-risk	592,561	%85,87
fit	39,803	%5,77
unhealthy	57,724	%8,36

Bu dengesizlik nedeniyle normal accuracy ana seçim metriği değildir. Balanced accuracy, üç sınıf recall değerinin ortalamasıdır ve azınlık sınıflarını eşit ağırlıkla değerlendirir.

2. Pipeline nasıl çalıştı?

CSV yükleme ve schema doğrulama

- > stratified 3-fold ayırma
- > her fold'da yalnız fold-train ile preprocessing fit
- > LightGBM + early stopping
- > fold-valid OOF probabilities
- > fold-test probabilities ve üç fold ortalaması
- > metrikler, modeller, importance, confusion matrix, ROC, manifest

- > seçili deneylerde OOF-only class multiplier tuning
- > argmax ve tuned submission üretimi
- > E002 feature pipeline üzerinde 20 trial parameter sweep

2.1 Fold-safe preprocessing

Median, kategori seviyeleri, outlier quantile ve clipping sınırları yalnız fold-train'de öğrenilir. Aynı dönüşüm fold-valid ve test'e uygulanır. Bu tasarım validation satırlarının kendi preprocessing istatistiklerini etkilemesini, yani veri sızıntısını önler.

2.2 LightGBM ve early stopping

Başlangıç modeli `learning_rate=0.035, num_leaves=96, min_child_samples=200, subsample=0.85, colsample_bytree=0.90, reg_alpha=0.1, reg_lambda=2.0` kullanır. `n_estimators=12000` yalnız üst sınırdır. Validation multi-logloss 300 tur iyileşmezse eğitim durur ve her fold'un en iyi iterasyonu kullanılır.

2.3 OOF ve test olasılıkları

Her train satırının OOF olasılığı, o satırı eğitimde görmeyen modelden gelir. Model seçimi, multiplier tuning ve rapordaki lokal metrikler bu olasılıklar üzerinden hesaplanır. Test olasılıkları üç fold modelinin ortalamasıdır.

3. Deney tasarımı: ne değiştirildi?

Deney	Pipeline	Değişiklik	Ölçülen hipotez
E001	V1 baseline	Median + missing category/flag	Güvenli referans
E002	V2-Core	Missing count, 6 ratio, 3 interaction, outlier flag/count	EDA feature set'i ek sinyal taşıyor mu?
E003	E002 + interaction	gender_activity	Gender/activity birlikte yararlı mı?
E004	E002 + rules	8 threshold flag	Açık eşikler rare-class recall artırıyor mu?
E005	E002 + clipping	Fold-train %0,1/%99,9 clipping	Uç değer sıkıştırma genellemeyi artırıyor mu?
E006	E002 + log	6 $\log_2(\text{ratio})$	Uzun kuyukları sıkıştırmak yararlı mı?
E007	Postprocess	OOF class multiplier	Argmax karar sınırı dengelenebilir mi?
E008	E002 + weight	Sqrt-balanced sample weight	Rare class eğitim ağırlığı faydalı mı?

Feature yöntemlerinin formülleri ve sayısal örnekleri ayrıca `experiments-detailed-explanation.md` belgesinde ayrıntılı olarak açıklanmıştır.

3.1 Feature üretim yöntemleri ve tam eşikler

Missing yönetimi

- 7 numeric kolon fold-train medianı ile doldurulur.
- 6 categorical kolon için eksik değer açık missing kategorisidir.
- Her ham kolon için `<kolon>_is_missing` ikili flag'i üretilir.
- E002 ve türevlerinde 13 ham kolondaki eksiklerin toplamı `missing_count` olur.
- Fold-train'de görülmeyen kategoriler `__UNKNOWN__` seviyesine taşınır.

Ratio feature'ları

Bütün oranlarda güvenli bölme `pay / (payda + 1)` kullanılır. +1, paydanın sıfır olduğu satırlarda sonsuz değer oluşmasını önler.

Feature	Formül	Amaç
<code>calorie_per_step</code>	<code>calorie_expenditure / (step_count + 1)</code>	Adım başına enerji
<code>calorie_per_exercise_min</code>	<code>calorie_expenditure / (exercise_duration + 1)</code>	Egzersiz süresine göre enerji
<code>step_per_exercise_min</code>	<code>step_count / (exercise_duration + 1)</code>	Egzersiz süresine göre hareket
<code>water_per_bmi</code>	<code>water_intake / (bmi + 1)</code>	BMI'a göre su tüketimi

Feature	Formül	Amaç
exercise_per_bmi	exercise_duration / (bmi + 1)	BMI'a göre egzersiz
steps_per_sleep_hour	step_count / (sleep_duration + 1)	Uyku süresine göre hareket

Categorical interaction'lar

stress_level__sleep_quality, physical_activity_level__diet_type ve smoking_alcohol__physical_activity_level birleşimleri yeni kategori olarak üretilir. E003 ayrıca gender__physical_activity_level ekler.

Outlier ve clipping eşikleri

- E002 outlier flag sınırları fold-train %0,5 ve %99,5 quantile'larıdır.
- Ham 7 numeric ve 6 ratio için _outlier_low/_outlier_high flag'leri üretilir.
- Aktif flag sayısı outlier_count olarak tutulur; satır silinmez.
- E005 clipping sınırları fold-train %0,1 ve %99,9 quantile'larıdır.
- Outlier flag clipping'den **önce** hesaplanır; uçta olma bilgisi korunur.

Rule flag eşikleri

Flag	Aktif olma koşulu
low_sleep_flag	sleep_duration < 6
high_sleep_flag	sleep_duration > 9
high_bmi_flag	bmi >= 30
low_bmi_flag	bmi < 18,5
high_heart_rate_flag	heart_rate > 100
low_heart_rate_flag	heart_rate < 60
low_steps_flag	step_count < 3.000
high_steps_flag	step_count > 12.000

Log dönüşümü ve sample weight

E006, her ratio için $\log(1 + \max(\text{ratio}, 0))$ varyantını orijinal feature'ı silmeden ekler. E008 sınıf ağırlığını fold-train sınıf sayısından hesaplar:


```
balanced_weight(class) = N / (3 * class_count)
sqrt_balanced_weight(class) = sqrt(balanced_weight(class))
```

Bu yöntem rare-class hatalarını eğitim loss'unda daha pahalı yapar fakat tam balanced weight'e göre çoğunluk sınıfını daha az baskılar.


4. Ana deney sonuçları

experiment	değişiklik	features	balanced_accuracy	accuracy	macro_f1	recall_at-risk	recall_fit	recall_unhealthy	early_iteration	E001
E001	Median imputasyon + missing flag	26	0.878103	0.001471	0.910199	0.991208	0.832400	0.810703	286.7	0.000000
E002	Missing count, ratio, interaction, outlier flag	63	0.876937	0.001883	0.909556	0.991228	0.829988	0.809594	242.0	- 0.001167
E003	E002 + gender_activity interaction	64	0.876819	0.001484	0.909159	0.991042	0.829510	0.809906	242.7	- 0.001284


experiment	değişiklik	features	balanced_accuracy	macro_f1	recall_at-risk	recall_fit	recall_unhealthy	early_iteration	std E001	
E004	E002 + sekiz eşik flag'i	71	0.877466	0.001418	0.909695	0.991127	0.830515	0.810755	242.3	-
E005	E002 + %0,1/%99,9 clipping	63	0.876661	0.001735	0.909403	0.991240	0.829133	0.809611	239.7	-
E006	E002 + altı log1p ratio	69	0.876852	0.001698	0.909415	0.991184	0.829812	0.809559	241.7	-
E008	E002 + sqrt-balanced sample weight	63	0.914002	0.001098	0.904713	0.975356	0.887395	0.879253	1369.3	0.035898



Şekil 1: Ana deney balanced accuracy




Şekil 2: Ana deney sınıf recall



Şekil 3: OOF tahmin dağılımları

4.1 Fold kararlılığı

Deney	Fold 0	Fold 1	Fold 2
E001	0.877880	0.879673	0.876757
E002	0.877184	0.878684	0.874942
E003	0.876783	0.878322	0.875354
E004	0.877834	0.878663	0.875900
E005	0.876932	0.878245	0.874807
E006	0.876850	0.878551	0.875154
E008	0.912759	0.914842	0.914404



Şekil 4: Fold kararlılığı

E008 yalnız ortalamada en iyi değildir; fold standard deviation değeri de ana deneylerin en düşüğüdür. `unhealthy` recall fold'lar arasında diğer sınıflardan daha fazla oynasa da üç fold'un tamamında E001/E002 seviyesinin belirgin üzerindedir.

4.2 Deney bazında kararlar


- **E001:** Güçlü baseline. 26 feature ile bütün ağırlıksız V2 varyantlarını geçmiştir.
- **E002:** EDA feature paketinin toplu eklenmesi -0.001167 kayıp üretmiştir. Tek tek feature'ların kötü olduğunu kanıtlamaz; paket olarak faydalı değildir.
- **E003:** Gender/activity interaction E002'yi geçmemiştir; gender shift riski karşılığında kazanım yoktur.
- **E004:** E002'ye $+0.000529$ ile ağırlıksız V2 varyantlarının en iyisidir; fark gürültü eşiğinin altındadır ve E001'i geçmez.
- **E005:** Clipping skoru düşürmüştür. Uç değerlerin hedef sinyali taşıdığı EDA bulgusuyla uyumludur.
- **E006:** Log ratio varyantları pratik olarak nötrdür; 6 ek feature karşılığında kazanım yoktur.
- **E008:** Açık kazanan argmax modeldir. Rare-class recall artışı ortalama skoru yaklaşık 0,037 yükseltmiştir.

5. E008 ayrıntılı teşhis

E008 overall accuracy 0.962244, balanced accuracy 0.914002, macro F1 0.904713, MCC 0.852788, log-loss 0.097448 ve macro OvR ROC-AUC 0.982905 üretmiştir.

5.1 Confusion matrix

Gerçek sınıf	at-risk	fit	unhealthy
at-risk	577958	5945	8658
fit	4351	35321	131
unhealthy	6877	93	50754




Şekil 5: E008 confusion matrix

fit örneklerinin büyük bölümü doğru bulunurken 4.351 tanesi *at-risk* tahmin edilmiştir. *unhealthy* için ana hata yönü yine *at-risk* sınıfıdır (6.877 satır). Bu davranış sonraki postprocess'in neden azınlık sınıfı multiplier'larını büyüttüğünü açıklar.

5.2 Feature importance


feature	importance_gain	importance_split
sleep_duration	2,291,532	28,169
stress_level	1,727,830	1,254
stress_sleep_quality	1,425,269	19,206
physical_activity_level	710,284	245
activity_diet	505,896	11,995
bmi	224,809	34,328
sleep_duration_is_missing	194,984	1,191
smoking_activity	156,925	12,435
stress_level_is_missing	147,586	872
steps_per_sleep_hour	144,854	21,121
step_count	117,190	19,768
heart_rate	113,610	34,576
calorie_expenditure	94,144	28,666
water_intake	93,704	26,762
water_per_bmi	85,159	26,205
exercise_per_bmi	78,575	20,776
exercise_duration	77,376	20,102
calorie_per_exercise_min	77,247	23,304
step_per_exercise_min	76,632	23,005
calorie_per_step	73,132	21,784




Şekil 6: E008 feature importance

Gain importance nedensellik değildir ve korelasyonlu feature'lar önemi paylaşabilir. Bununla birlikte sleep_duration, stress_level ve physical_activity_level ana sinyal kaynaklarıdır. Missing flag ve engineered feature katkıları ham feature'ların gölgesindedir.

5.3 ROC ve eğitim geçmişi



Şekil 7: Seçili ROC eğrileri



Şekil 8: E008 training history

ROC-AUC sınıfların olasılık sıralamasını, balanced accuracy ise seçilen kararın recall dengesini ölçer. E008 macro OvR ROC-AUC değeri yüksek olduğu için model olasılıklarının sıralama gücü vardır; multiplier tuning bu sıralamayı farklı karar sınırına çevirir. Training history'deki dikey çizgiler fold best-iteration noktalarını gösterir.

6. E007 — Class multiplier / karar sınırı optimizasyonu

Varsayılan karar $\text{argmax}(\text{probability})$ iken tuned karar şöyledir:


```
prediction = argmax(probability * class_multiplier)
```

Arama, at-risk=1 referansı ile fit ve unhealthy için 0,80–1,50 coarse grid (841 aday), ardından en iyi komşulukta seeded 2.000 random trial uygular. Son vektör ortalaması 1 olacak şekilde normalize edilir.

experiment	argmax	tuned	delta	macro_f1	recall_at-risk	recall_fit	recall_unhealthy	mult_at-risk	mult_fit	mult_unhealthy
E002	0.876937	0.948584	0.071648	0.874625	0.942892	0.945356	0.957505	0.189230	1.444453	1.366317
E004	0.877466	0.948188	0.070722	0.875702	0.943705	0.944150	0.956708	0.201875	1.383380	1.414746
E006	0.876852	0.948308	0.071456	0.875199	0.943359	0.944753	0.956812	0.196463	1.413557	1.389980
E008	0.914002	0.947802	0.033800	0.872550	0.941351	0.943371	0.958683	0.226480	1.350305	1.423215



Şekil 9: Multiplier tuning kazancı



Şekil 10: Multiplier değerleri

6.1 Kritik metodolojik uyarı

Multiplier aynı OOF tahminleri üzerinde hem **seçilmiş** hem **raporlanmıştır**. 2.841 aday arasından en iyiyi seçmek, OOF skoruna seçim yanlılığı ekleyebilir. Bu nedenle 0.948584 bağımsız bir holdout skoru gibi kabul edilmemelidir. Güvenilirlik sırası:


1. Aynı multiplier'ı farklı seed OOF tahminlerinde doğrulamak.
2. Nested CV ile her dış fold için multiplier'ı yalnız diğer fold'larda seçmek.
3. Public LB'de bir argmax/tuned çiftini kontrollü karşılaştırmak.

Tuned adaylar arasında fark yalnız yaklaşık 0,0008'dir; tek başına bu sıralama kesin model üstünlüğü sayılmaz.


7. LightGBM sweep sonuçları

Sweep yalnız E002 feature pipeline üzerinde çalışmıştır; E008'in sample weighting yaklaşımı sweep'e dahil değildir. Aşağıdaki tablo 20 trial'ın tamamını OOF balanced accuracy'ye göre sıralar.

rank	experiment	balanced_accuracy	accuracy	learning_rate	num_leaves	min_child_samples	alpha	reg_lambda	subsample	colsample_bytree	best_iteration
1	SWEEP_002	0.77851	0.001796	0.04	127	200	0.0	10.0	0.85	0.95	195.0
2	SWEEP_003	0.77651	0.001627	0.02	127	400	0.05	2.0	0.95	0.75	446.0
3	SWEEP_003	0.77638	0.001237	0.03	31	800	0.5	5.0	0.85	1.0	444.7
4	SWEEP_001	0.77442	0.001176	0.02	96	400	0.5	2.0	0.75	1.0	391.3
5	SWEEP_003	0.77432	0.001984	0.05	127	400	0.05	5.0	0.75	1.0	140.3
6	SWEEP_007	0.77399	0.001329	0.02	96	400	0.1	2.0	0.95	0.95	435.0
7	SWEEP_002	0.77287	0.001695	0.04	127	50	0.05	5.0	0.95	0.85	201.0
8	SWEEP_007	0.77255	0.001893	0.05	127	50	0.05	2.0	0.85	0.75	176.7
9	SWEEP_003	0.77240	0.001091	0.02	191	800	0.05	5.0	0.75	1.0	343.0
10	SWEEP_003	0.77229	0.001078	0.05	191	100	0.5	1.0	0.75	0.95	121.3
11	SWEEP_001	0.77188	0.001641	0.04	63	50	0.1	10.0	0.95	1.0	232.7
12	SWEEP_004	0.77127	0.001357	0.04	31	800	0.0	10.0	0.75	1.0	293.7
13	SWEEP_003	0.77116	0.001457	0.04	96	200	0.1	0.5	0.75	0.75	230.0
14	SWEEP_004	0.77107	0.001424	0.04	96	200	0.0	0.5	0.85	1.0	205.3
15	SWEEP_006	0.77017	0.001423	0.04	63	50	0.5	2.0	0.95	0.95	257.0
16	SWEEP_008	0.77014	0.001742	0.02	127	200	0.1	2.0	0.85	0.75	436.0
17	SWEEP_009	0.76863	0.001682	0.04	127	100	0.1	0.5	0.85	0.85	211.7
18	SWEEP_009	0.76746	0.001288	0.05	96	100	0.5	1.0	0.75	0.85	155.7
19	SWEEP_008	0.76665	0.001073	0.04	31	400	0.1	10.0	0.95	0.85	345.7
20	SWEEP_003	0.76204	0.000936	0.05	31	200	0.0	5.0	0.85	0.85	272.3



Şekil 11: Sweep skorları



Şekil 12: Sweep parametre etkileri

Parametre grafiği kontrollü tek-değişken deneyi değildir: her trial aynı anda birden fazla parametreyi değiştirdiği için noktalar nedensel etki olarak okunmamalıdır. Yalnız arama uzayında hangi seviyelerin daha iyi trial'larla birlikte görüldüğünü özetler.


7.1 Sweep yorumu

- En iyi trial **SWEEP_002**, parametreleri: learning_rate=0.04, num_leaves=127, min_child_samples=200, reg_alpha=0.0, reg_lambda=10.0, subsample=0.85, colsample_bytree=0.95.
- En iyi ile en kötü sweep arasındaki aralık yalnız 0.001647'dir.
- Hiçbir sweep E008'e yaklaşmamıştır.
- Aynı 3 fold üzerinde 20 aday seçildiği için en iyi trial skoru da hafif seçim yanlılığı taşıyabilir.
- Sonraki HPO, yapılırsa E008 veya E001+sqrt-balanced tabanı üzerinde ve ayrı seed ile doğrulanmalıdır.


8. Submission adaylarının doğrulanması

candidate	file	rows	at-risk	fit	unhealthy	labels_valid	id_unique
E001_argmax	outputs/experiments/2957501/submission_argmax.csv	2957501	%5,12	%5,12	%7,06	True	True
E002_argmax	outputs/experiments/2957502/submission_argmax.csv	2957502	%5,09	%5,09	%7,05	True	True
E002_tuned	outputs/experiments/2957502/submission_argmax.csv	2957502	%11,12	%11,12	%11,12	True	True
E004_tuned	outputs/experiments/2957504/submission_argmax.csv	2957504	%11,07	%11,07	%11,07	True	True
E006_tuned	outputs/experiments/2957506/submission_argmax.csv	2957506	%11,09	%11,09	%11,09	True	True
E008_argmax	outputs/experiments/2957508/submission_argmax.csv	2957508	%8,56	%8,56	%8,56	True	True
E008_tuned	outputs/experiments/2957508/submission_argmax.csv	2957508	%11,35	%11,35	%11,35	True	True
SWEEP_002_argmax	outputs/experiments/2957509/submission_argmax.csv	2957509	%5,10	%5,10	%7,09	True	True

Bütün kısa liste dosyaları 295.753 satır, benzersiz ID, doğru iki kolon ve izin verilen üç label kontrolünü geçmiştir.



Şekil 13: Submission dağılımları



Şekil 14: Submission disagreement

8.1 Disagreement nasıl okunur?

Pairwise disagreement, iki submission'ın farklı label verdiği test satırı oranıdır. Düşük oran iki dosyanın günlük submit hakkı açısından birbirini tekrar ettiğini; daha yüksek oran ise farklı karar sınırı veya model davranışı taşıdığını gösterir. Fakat çeşitlilik tek başına kalite kanıtı değildir.

En yüksek kısa-liste disagreement: E002_argmax ile E008_tuned arasında 6.41%.

9. Submission seçimi için karar matrisi

Aday	Güçlü yön	Ana risk	Önerilen rol
E008 argmax	En iyi bağımsız ana deney skoru, düşük fold std	Tuned modellere göre düşük OOF skor	Güvenli ilk referans
E002 tuned	En iyi tuned OOF skoru	Multiplier seçim yanlılığı	Ana tuned aday
E006 tuned	E002 tuned'a çok yakın, farklı feature set	Log feature katkısı kanıtlanmadı	İkinci tuned aday
E008 tuned	En yüksek unhealthy recall	E002 tuned'dan düşük, postprocess overfit	Recall-ağırlıklı aday
SWEEP_002 argmax	En iyi HPO trial	E001'den iyi değil	HPO kontrol adayı
E001 argmax	En güçlü sade ağırlıksız baseline	Rare-class recall düşük	Baseline kontrolü

9.1 Önerilen kontrollü submit sırası

Bu sıra lokal kanıta dayanır; yarışma leaderboard sonucu bilinmeden kesin kazanan iddiası değildir.

1. outputs/experiments/E008/submission_E008_argmax.csv

2. outputs/experiments/E002/submission_E002_tuned.csv
3. outputs/experiments/E008/submission_E008_tuned.csv
4. outputs/experiments/E006/submission_E006_tuned.csv
5. Gerekirse SWEEP_002/submission_argmax.csv

İlk iki dosya, eğitimde sınıf ağırlığı ile postprocess karar sınırının leaderboard'daki gerçek katkısını ayırmak için en bilgi verici çifttir. Birbirine çok yakın tuned varyantların tamamını aynı gün göndermek yerine sonuç geldikçe sonraki aday seçilmelidir.

10. Bilinen riskler ve eksik doğrulamalar

1. **Tek CV seed:** Bütün ana deneyler seed 42 ile aynı üç fold'u kullanır.
2. **Multiplier overfit:** Class multiplier aynı OOF üzerinde seçilip değerlendirilmiştir.
3. **Sweep selection bias:** 20 aday aynı fold'larda karşılaştırılmıştır.
4. **Public/private LB farkı:** Test target dağılımı ve hidden split bilinmez.
5. **Feature importance nedensel değildir:** Gain değerleri yalnız model içi kullanım ölçüsüdür.
6. **Probability calibration ölçülmedi:** Balanced accuracy iyi olsa bile olasılıkların kalibrasyonu ayrıca doğrulanmamıştır.
7. **E001 + sqrt-balanced eksik:** Ağırlık kazancının V2 feature set'e bağlı olup olmadığını ayıracak en önemli yeni ablation henüz çalıştırılmamıştır.

11. Sonraki en değerli deneyler

1. **E009 = E001 + sqrt-balanced:** Baseline feature'larla weighting etkisini izole et.
2. **Multi-seed doğrulama:** E001, E008, E002-tuned için en az 3 ek seed.
3. **Nested multiplier CV:** Postprocess iyimserliğini ölç.
4. **E008 tabanlı küçük sweep:** HPO'yu sınıf ağırlıklı kazanan pipeline'a uygula.
5. **OOF probability blend:** E008 ve E002/E006 olasılıklarını yalnız OOF ile ağırlıklandır.

12. Artefakt ve kaynak dizini

- Ana sonuçlar: outputs/experiments/E001 ... E008
- Sweep sonuçları: outputs/experiments/SWEEP_000 ... SWEEP_019
- Lokal leaderboard: outputs/leaderboard_local.csv
- Pipeline logu: outputs/logs/pipeline_20260704_143235.log
- Deney config'i: configs/experiments.yaml
- Model config'i: configs/lgbm_base.yaml
- Sweep uzayı: configs/sweeps.yaml
- Eğitim kodu: src/kaggle_s6_e7/training.py
- Postprocess kodu: src/kaggle_s6_e7/postprocess.py
- Bu raporun üreticisi: scripts/generate_experiment_report.py

Rapor yalnız repository içindeki gerçekleşmiş artefaktlardan üretilmiştir. Public veya private leaderboard skoru içermez.